

Datenbedarf & Forschungskonzept: Textkomplexität über Preprint-Versionen

Forschungsfrage

Verändert sich die Textkomplexität wissenschaftlicher Preprints zwischen Versionen systematisch? Konkret: Werden Papers von der ersten Preprint-Version (v1) über weitere Revisionen bis zur publizierten Fassung sprachlich einfacher oder komplexer — und gibt es dabei Muster, die über einzelne Papers hinaus stabil sind? Potenziell könnte man daraus ablesen, wie sich die Dynamik zwischen Autor und Peer Reviews über Versionen hinaus entwickelt.

Hypothesen:

- H1: Die finale Fassung ist einfacher formuliert als v1 (redaktionelle Überarbeitung glättet Sprache).
 - H2: Spätere Preprint-Versionen werden sukzessive einfacher (Autoren passen Text an Reviewer-Feedback an).
-

Messung

Pro Version jedes Papers werden folgende Metriken auf dem Haupttext berechnet:

Lesbarkeit: Flesch Reading Ease, Flesch-Kincaid Grade Level, Gunning Fog Index, durchschnittliche Satz- und Wortlänge

Lexik: Type-Token Ratio (auf Fenstern à 500 Token), Anteil seltener Wörter außerhalb der 10.000 häufigsten englischen Wörter

Wissenschaftsspezifisch: Passive-Voice-Rate, Nominalisierungsrate, Hedge-Ratio (*may*, *suggest*, *indicate* ...)

Versionsvergleich: Für jede Metrik wird die Differenz zwischen aufeinanderfolgenden Versionen (Δ) berechnet, um Papers vergleichbar zu machen.

Benötigte Daten

Wir haben die Liste der DOIs der 959 benötigten Papers angehängt. Wir brauchen dabei vor allem die Texte aller Versionen sowie die üblichen Metadaten aus der SampleData.
